Modelización Estadística

Proyecto y rama del trabajo en GitHub.

E.T.S de Ingeniería Informática - Universidad de Málaga.

Trabajo elaborado por: Antonio J. Galán Herrera

Aclaraciones previas:

- Se ha evitado el uso de acentos en el script para evitar caracteres raros al guardarlo en formato UTF-8.
- Las rutas a ficheros están escritas de forma relativa a la carpeta de la entrega, por lo que el script fallará al leer los datos si se ejecuta en otra ubicación.
- El apartado 11 solo se encuentra en este documento, no en el script.
- Se han eliminado algunos de los comentarios del script en las secciones de código del documento para que no haya explicaciones duplicadas.

Apartado 01

Código de R

```
# Usando la funcion 'read_csv' del paquete 'readr'
# se exporta el fichero con formato 'tibble'.
datos <- read_csv("../Recursos/12306.csv", col_types=cols(sexo=col_factor(),
                                                          dietaEsp=col_factor(),
                                                          nivEstPad=col_factor(),
                                                          nivEstudios=col_factor(),
                                                          nivIngresos=col_factor()))
```

Resultado

```
> datos
# A tibble: 5,000 x 14
    peso altura sexo   edad tabaco  ubes carneRoja verduras deporte drogas dietaEsp
   <dbl>  <dbl> <fct> <dbl>  <dbl> <dbl>     <dbl>    <dbl>   <dbl>  <dbl> <fct>
 1  81.6   1.71 V        18      0     0         3       11       4      0 N
 2 101.    1.61 M        56      0     0         3        5       5      0 N
 3 103.    1.83 V        42      0     0         4        7       0      0 N
```

```
 4 113.    1.75 V        39      0     0         1       16       7      0 N
 5  55.8   1.76 V        43    110     0         2        0       0      1 N
 6  68.0   1.67 M        21      0    11         0       13       0      1 N
 7  66.6   1.58 M        74    130     6         0        0      11      0 N
 8 101.    1.7  V        50      0     3         0       29      18      0 N
 9  81.4   1.69 M        35      0     4         0       14       3      0 N
10  76.1   1.67 M        18      0     0         6        0      10      2 S
# … with 4,990 more rows, and 3 more variables: nivEstPad <fct>, nivEstudios <fct>,
#   nivIngresos <fct>
```

Variables:

- `datos` con los valores del fichero ordenados en 14 columnas, 9 de ellas variables cuantituativas y 5 de ellas variables cualitativas.

Explicación

Los datos del fichero `12306.csv` se exportan en un formato de valores separados por comas.

Con R puede leerse dichos valores haciendo uso de la función `read_csv()` de la librería `tidyverse`; estos se almacenarán en un dataframe en formato `tibble`, que facilitará el manejo de los valores durante el resto de apartados del trabajo.

Como se puede ver, la lectura incorpora la factorización de 5 variables, debido a que son cualitativas.

Apartado 02

Código de R

```
# Se crea la columna 'IMC' segun el enunciado
datos <- mutate(datos, IMC = peso / altura^2)
```

Resultado

```
> datos
# A tibble: 5,000 x 15
    peso altura sexo   edad tabaco  ubes carneRoja verduras deporte drogas dietaEsp
   <dbl>  <dbl> <fct> <dbl>  <dbl> <dbl>     <dbl>    <dbl>   <dbl>  <dbl> <fct>
 1  81.6   1.71 V        18      0     0         3       11       4      0 N
 2 101.    1.61 M        56      0     0         3        5       5      0 N
 3 103.    1.83 V        42      0     0         4        7       0      0 N
 4 113.    1.75 V        39      0     0         1       16       7      0 N
 5  55.8   1.76 V        43    110     0         2        0       0      1 N
 6  68.0   1.67 M        21      0    11         0       13       0      1 N
 7  66.6   1.58 M        74    130     6         0        0      11      0 N
 8 101.    1.7  V        50      0     3         0       29      18      0 N
 9  81.4   1.69 M        35      0     4         0       14       3      0 N
10  76.1   1.67 M        18      0     0         6        0      10      2 S
# … with 4,990 more rows, and 4 more variables: nivEstPad <fct>, nivEstudios <fct>,
#   nivIngresos <fct>, IMC <dbl>
```

Variables:

- `datos` con una nueva columna llamada *IMC*, cuyos valores se obtienen operando los de las columnas *peso* y *altura*.

Explicación

En R, es habitual usar la función `mutate()` para modificar un dataframe añadiéndole columnas, lo que permite reutilizar la misma variable actualizando su contenido.

En este caso, como los valores están en `datos`, basta con añadir una nueva columna a esa variable, en lugar de generar otra variable nueva que contenga la misma información junto a la añadida.

Apartado 03

Código de R

```
# Se limpian las filas con algun NA de los datos,
# usando la funcion 'na.exclude()' o 'na.omit()'
datos <- na.exclude(datos)
```

Resultado

```
> datos
# A tibble: 4,950 x 15
    peso altura sexo   edad tabaco  ubes carneRoja verduras deporte drogas dietaEsp
   <dbl>  <dbl> <fct> <dbl>  <dbl> <dbl>     <dbl>    <dbl>   <dbl>  <dbl> <fct>
 1  81.6   1.71 V        18      0     0         3       11       4      0 N
 2 101.    1.61 M        56      0     0         3        5       5      0 N
 3 103.    1.83 V        42      0     0         4        7       0      0 N
 4 113.    1.75 V        39      0     0         1       16       7      0 N
 5  55.8   1.76 V        43    110     0         2        0       0      1 N
 6  68.0   1.67 M        21      0    11         0       13       0      1 N
 7  66.6   1.58 M        74    130     6         0        0      11      0 N
 8 101.    1.7  V        50      0     3         0       29      18      0 N
 9  81.4   1.69 M        35      0     4         0       14       3      0 N
10  76.1   1.67 M        18      0     0         6        0      10      2 S
# … with 4,940 more rows, and 4 more variables: nivEstPad <fct>, nivEstudios <fct>,
#   nivIngresos <fct>, IMC <dbl>
```

Variables:

- `datos` con 10 filas menos, donde en cada una de esas filas había al menos un valor NA para alguna de las columnas.

Explicación

Durante el resto de apartados será necesario que no haya valores NA, ya que interfieren con los procesos de cálculo.

Usando la funcion `na.exclude()` se eliminan de un dataframe todas las filas completas que contengan un NA en alguna de sus columnas, obteniendo un `tibble` donde todos los valores son computables.

Apartado 04

Código de R

```
# Calcula la desviacion tipica.
# * datos:  vector con los valores para el calculo
dt <- function(datos) {
  sqrt(mean(datos^2) - mean(datos)^2)
}


# Quitar variables cualitativas (factores) de los datos
datosN <- Filter(is.numeric, datos)


# Medias
medias <- colMeans(datosN)

# Desviaciones tipicas
desviaciones <- map_dbl(datosN, dt)
```

Resultado

```
> datosN
# A tibble: 4,950 x 10
    peso altura  edad tabaco  ubes carneRoja verduras deporte drogas   IMC
   <dbl>  <dbl> <dbl>  <dbl> <dbl>     <dbl>    <dbl>   <dbl>  <dbl> <dbl>
 1  81.6   1.71    18      0     0         3       11       4      0  27.9
 2 101.    1.61    56      0     0         3        5       5      0  39.1
 3 103.    1.83    42      0     0         4        7       0      0  30.9
 4 113.    1.75    39      0     0         1       16       7      0  37.0
 5  55.8   1.76    43    110     0         2        0       0      1  18.0
 6  68.0   1.67    21      0    11         0       13       0      1  24.4
 7  66.6   1.58    74    130     6         0        0      11      0  26.7
 8 101.    1.7     50      0     3         0       29      18      0  35
```

```
 9  81.4   1.69    35      0     4         0       14       3      0  28.5
10  76.1   1.67    18      0     0         6        0      10      2  27.3
# … with 4,940 more rows

> medias
      peso     altura       edad     tabaco       ubes  carneRoja   verduras
86.9590485  1.7007192 40.5456566 19.4121212  3.9446465  1.7507071  6.0218182
   deporte     drogas        IMC
 4.0812121  0.4967677 30.0140191

> desviaciones
       peso      altura        edad      tabaco        ubes   carneRoja    verduras
18.57074700  0.06994665 13.97470429 41.67645769  5.79335797  2.11002286  7.08233888
    deporte      drogas         IMC
 4.63049516  1.47034307  5.89044675
```

Funciones:

- `dt()` que calcula la desviación típica de un conjunto de datos.

Variables:

- `datosN` que contiene todas las columnas asociadas a variables cuantitativas.
- `medias` que contiene la media de todos los valores de cada variable cuantitativa.
- `desviaciones` que contiene las desviaciones típicas de todos los valores de cada variable cuantitativa.

Explicación

Pese a que R tiene una función llamada `sd()` que dice calcular la desviación típica, en realidad lo que calcula es la cuasivarianza; por eso, para este apartado se ha generado una función `dt()` que calcula la desviación típica real.

Por otra parte, aunque se hayan limpiado los datos de valores NA, aún quedan las columnas de tipo factor, que también deben ser suprimidas; usando la función `Filter()` se extraen las columnas numéricas y una vez obtenidos todos los datos numéricos en `datosN`, se puede calcular tanto las medias como las desviaciones típicas, usando `colMeans()` en la primera y un `map_dbl(sd, ...)` en la segunda.

La primera también podría haberse hecho con un `map_dbl(mean, ...)`, pero de la otra forma es más directo.

Apartado 05

Código de R

```
# Realiza el ajuste lineal sobre un conjunto de datos.
# * datos:  conjunto de datos
# * y:      variable a explicar
# * x:      variable explicatoria
ajusteLineal <- function(datos, y, x) {

  # lm(str_c(y, "~", x), df)  # Deprecado: Apartado 09
  lm(str_c(y, "~", str_c(x, collapse="+")), datos)
}


# Variables para los modelos
variables <- names(datos[3:14]) # Todas excepto "altura", "peso" e "IMC"


# Modelos
modelos <- variables %>% map(ajusteLineal, datos=datos, y="IMC")

# Coeficientes de regresion y determinacion de los modelos
regresion     <- modelos %>% map(coefficients)
determinacion <- modelos %>% map(summary) %>% map("r.squared")
```

Resultado

```
> variables
 [1] "sexo"        "edad"        "tabaco"      "ubes"        "carneRoja"
 [6] "verduras"    "deporte"     "drogas"      "dietaEsp"    "nivEstPad"
[11] "nivEstudios" "nivIngresos"

> modelos
```

```
[[1]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)        sexoM
   30.03841     -0.04953


[[2]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)         edad
    21.2284       0.2167


[[3]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)       tabaco
   31.85370     -0.09477


[[4]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)         ubes
    30.6699      -0.1663


[[5]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)    carneRoja
   29.93258      0.04652


[[6]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)     verduras
   29.59500      0.06958


[[7]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)      deporte
    29.2560       0.1857


[[8]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)       drogas
   30.02405     -0.02019


[[9]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)    dietaEspS
    30.0075       0.1405
```

```
[[10]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)   nivEstPad2   nivEstPad1   nivEstPad3   nivEstPad4
     32.117       -3.476       -1.810       -4.471       -4.863


[[11]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
 (Intercept)  nivEstudios0  nivEstudios4  nivEstudios1  nivEstudios2
      28.409         5.557        -1.696         4.072         1.915


[[12]]

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
 (Intercept)  nivIngresos0  nivIngresos4  nivIngresos1  nivIngresos2
      28.929         4.303        -1.566         2.790         1.103



> regresion
[[1]]
(Intercept)       sexoM
30.03840547 -0.04953317

[[2]]
(Intercept)        edad
 21.2283553   0.2166857

[[3]]
(Intercept)      tabaco
31.85369517 -0.09476945

[[4]]
(Intercept)        ubes
 30.6698557  -0.1662599

[[5]]
(Intercept)   carneRoja
29.93257548  0.04652044

[[6]]
(Intercept)    verduras
  29.595003    0.069583

[[7]]
(Intercept)     deporte
 29.2559836   0.1857379

[[8]]
(Intercept)      drogas
30.02404815 -0.02018853

[[9]]
(Intercept)   dietaEspS
 30.0074624   0.1405014

[[10]]
(Intercept)  nivEstPad2  nivEstPad1  nivEstPad3  nivEstPad4
  32.116791   -3.476127   -1.809982   -4.470905   -4.862785

[[11]]
 (Intercept) nivEstudios0 nivEstudios4 nivEstudios1 nivEstudios2
   28.408778     5.556721    -1.696364     4.071621     1.915136

[[12]]
 (Intercept) nivIngresos0 nivIngresos4 nivIngresos1 nivIngresos2
   28.929490     4.303432    -1.566490     2.789610     1.102659


> determinacion
[[1]]
[1] 1.767394e-05

[[2]]
[1] 0.2642709

[[3]]
[1] 0.4495954
```

```
[[4]]
[1] 0.02673864

[[5]]
[1] 0.0002776933

[[6]]
[1] 0.006999438

[[7]]
[1] 0.02131863

[[8]]
[1] 2.539513e-05

[[9]]
[1] 2.531141e-05

[[10]]
[1] 0.06195507

[[11]]
[1] 0.1527215

[[12]]
[1] 0.1123886
```

Funciones:

- `ajusteLineal()` que realiza un ajuste lineal sobre los datos.
- `variables` que contiene el nombre de todas las variables excepto *peso*, *altura* e *IMC*.
- `modelos` que es una lista de los modelos de regresión simple unidimensionales para todas las variables de `variables`.
- `regresion` que contiene los coeficientes de los modelos de `modelos`, donde se puede observar el coeficiente de regresión.
- `determinacion` que contiene los coeficientes de determinación de los modelos de `modelos`, correspondiente a R^2.

Explicación

Tras definir la función `ajusteLineal()` para que el proceso sea un poco más modular, se obtienen los nombres de las variables que la función va a recibir como argumento para generar los diferentes modelos.

Se excluye *IMC* por ser la variable explicada, así como *peso* y *altura* por generar el *IMC*.

Una vez obtenidos los modelos aplicando la función con `map()`, pueden obtenerse los coeficientes de regresión y de determinación en el contenido de la propia variable `modelos`.

Esto es posible debido a que `ajusteLineal()` usa `lm()` en su interior, que genera dichos valores de forma automática, por lo que solo hay que llamarlos.

Apartado 06

Código de R

```
# Igual que 'ajusteLineal()', pero devuelve una lista con los valores
# 'x' e 'y' del modelo, ademas del propio modelo y los datos.
# * datos:  conjunto de datos
# * y:      variable a explicar
# * x:      variable explicatoria
ajusteLinealLista <- function(datos, y, x) {
  list(x=x, y=y, modelo=lm(str_c(y, "~", str_c(x, collapse="+")), datos))
}

# Genera los graficos de dispersion junto a la recta de regresion
# * datos:  conjunto de datos del que extraer el grafico
# * modelo: modelo del que extraer la recta de regresion
dibujarModelos <- function(datos, modelo) {

  # Crear el fichero de la imagen (la carpeta debe existir)
  jpeg(str_c("Graficos/", modelo$x, ".jpeg"))

  # Valores numericos
  x <- datos[[modelo$x]]
  y <- datos[[modelo$y]]
```

```
  # Nombres
  ejeX <- modelo$x
  ejeY <- modelo$y

  # Representar los graficos
  plot(x, y, xlab=ejeX, ylab=ejeY, col=4)

  # Añadir la recta de regresion solo si es una variable cuantitativa
  if (is.numeric(datos[[modelo$x]])) {
    abline(modelo$modelo, col=1)
  }

  # Terminar de escribir en el fichero
  dev.off()
}


# Generar los modelos con los valores necesarios para las graficas
modelos <- variables %>% map(ajusteLinealLista, datos=datos, y="IMC")

# Dibujar todos los modelos
modelos %>% walk(~dibujarModelos(datos, .))
```

Resultado

```
> modelos
[[1]]
[[1]]$x
[1] "sexo"

[[1]]$y
[1] "IMC"

[[1]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)        sexoM
   30.03841     -0.04953



[[2]]
[[2]]$x
[1] "edad"

[[2]]$y
[1] "IMC"

[[2]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)         edad
    21.2284       0.2167



[[3]]
[[3]]$x
[1] "tabaco"

[[3]]$y
[1] "IMC"

[[3]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)       tabaco
   31.85370     -0.09477



[[4]]
[[4]]$x
[1] "ubes"
```

```
[[4]]$y
[1] "IMC"

[[4]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)         ubes
    30.6699      -0.1663



[[5]]
[[5]]$x
[1] "carneRoja"

[[5]]$y
[1] "IMC"

[[5]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)    carneRoja
   29.93258      0.04652



[[6]]
[[6]]$x
[1] "verduras"

[[6]]$y
[1] "IMC"

[[6]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)     verduras
   29.59500      0.06958



[[7]]
[[7]]$x
[1] "deporte"

[[7]]$y
[1] "IMC"

[[7]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)      deporte
    29.2560       0.1857



[[8]]
[[8]]$x
[1] "drogas"

[[8]]$y
[1] "IMC"

[[8]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)       drogas
   30.02405     -0.02019



[[9]]
[[9]]$x
[1] "dietaEsp"
```

```
[[9]]$y
[1] "IMC"

[[9]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)    dietaEspS
    30.0075       0.1405



[[10]]
[[10]]$x
[1] "nivEstPad"

[[10]]$y
[1] "IMC"

[[10]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)   nivEstPad2   nivEstPad1   nivEstPad3   nivEstPad4
     32.117       -3.476       -1.810       -4.471       -4.863



[[11]]
[[11]]$x
[1] "nivEstudios"

[[11]]$y
[1] "IMC"

[[11]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
 (Intercept)  nivEstudios0  nivEstudios4  nivEstudios1  nivEstudios2
      28.409         5.557        -1.696         4.072         1.915



[[12]]
[[12]]$x
[1] "nivIngresos"

[[12]]$y
[1] "IMC"

[[12]]$modelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
 (Intercept)  nivIngresos0  nivIngresos4  nivIngresos1  nivIngresos2
      28.929         4.303        -1.566         2.790         1.103
```

Funciones:

- `ajusteLinealLista()` que usando la función `ajusteLineal()`, obtiene otros datos de los modelos.
- `dibujarModelos()` que crea gráficos individuales para cada modelo: dispersión para variables cuantitativas y caja y bigote para variables cualitativas. Estos gráficos se guardan en ficheros en la carpeta *Graficos* de la entrega.

Variables:

- `modelos` actualizada que contiene, para cada valor del vector:
  - `x` con la variable x de ese modelo.
  - `y` con la variable y de ese modelo.
  - `modelo` con el propio modelo calculado.
  - `datos` con los datos que se usaron para el modelo.

Además, este apartado en concreto genera gráficos de dispersión para los modelos con variables cuantitativas, así como gráficos de caja y bigote para las variables cualitativas.

Gráficos

> Las imágenes originales (mejor resolución) se encuentran en el directorio *Graficos* de la misma entrega.

Se ha decidido usar el color azul para los datos ya que de esta forma, puede resaltarse la recta de regresión.

Variables cuantitativas

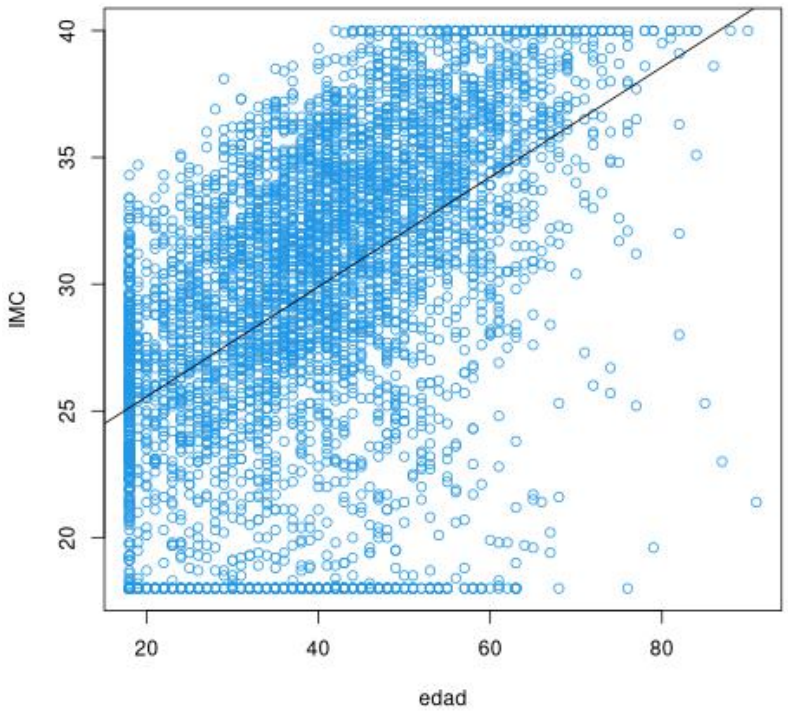

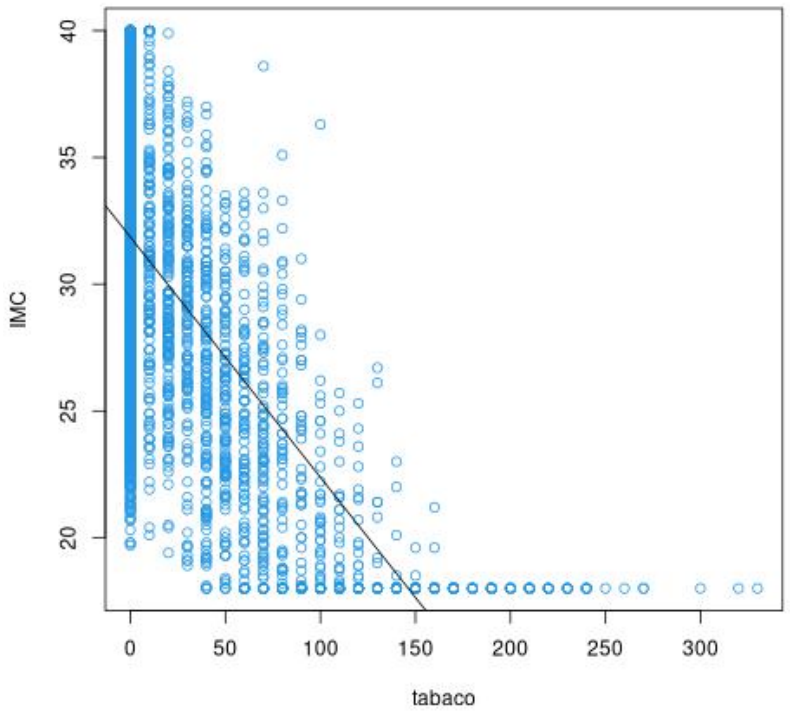

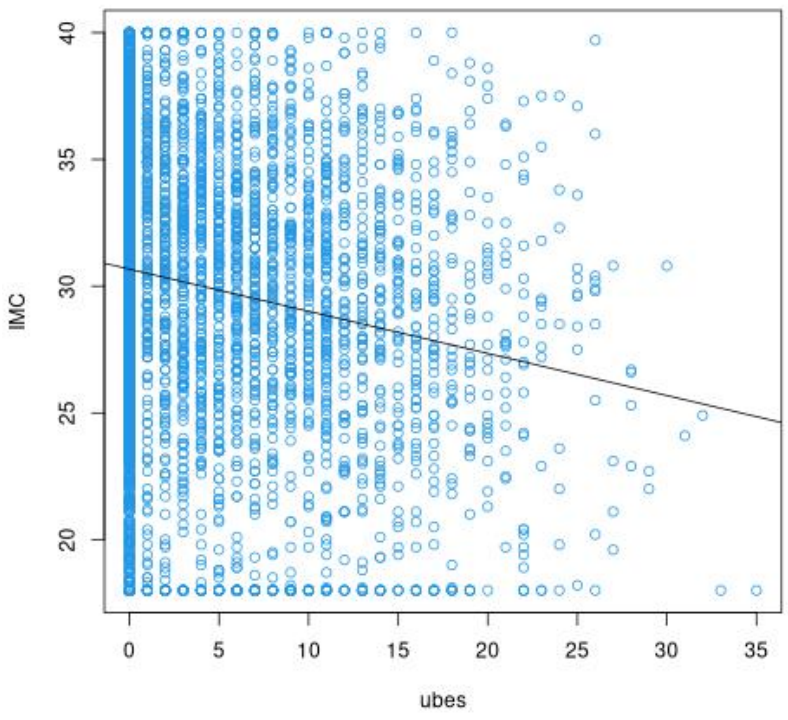

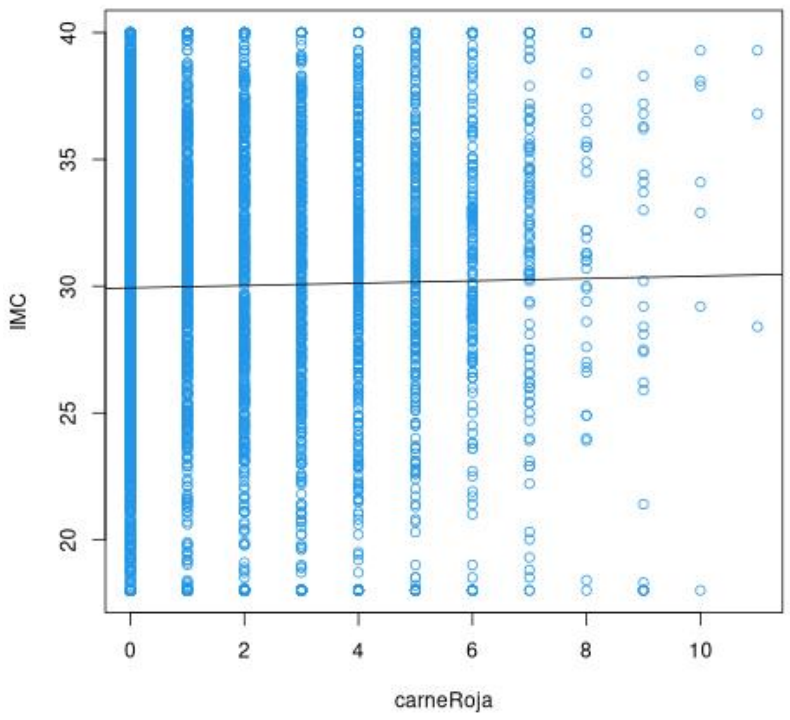

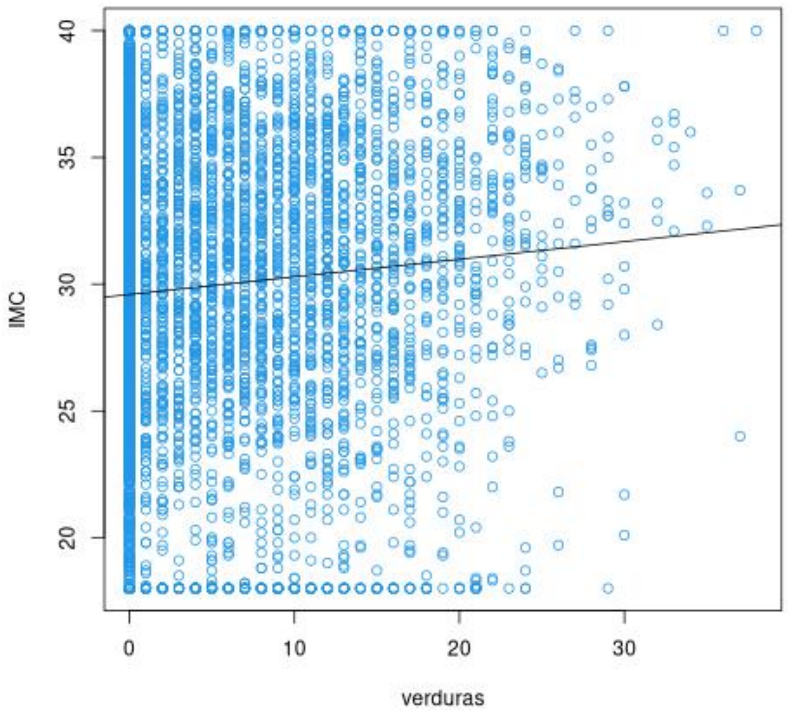

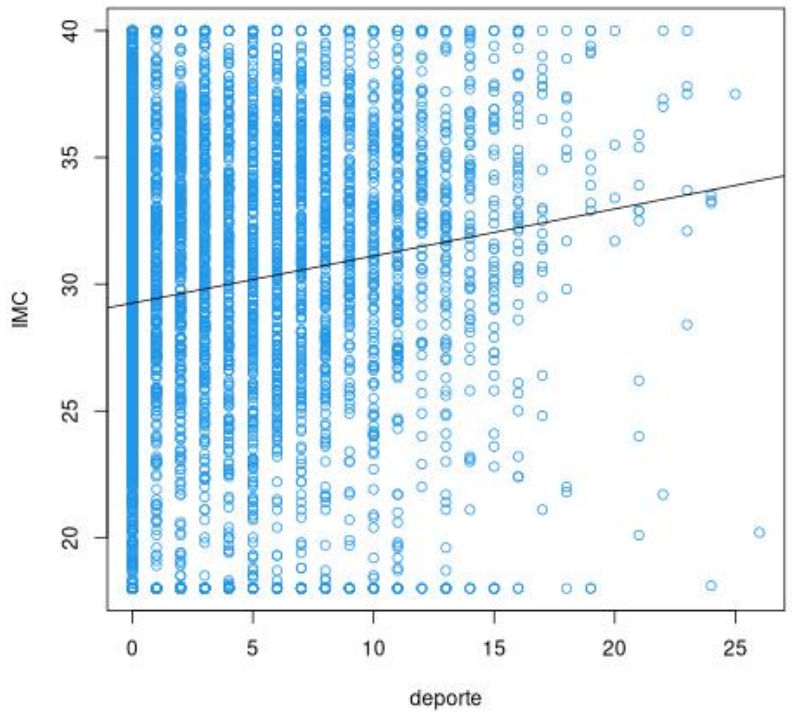

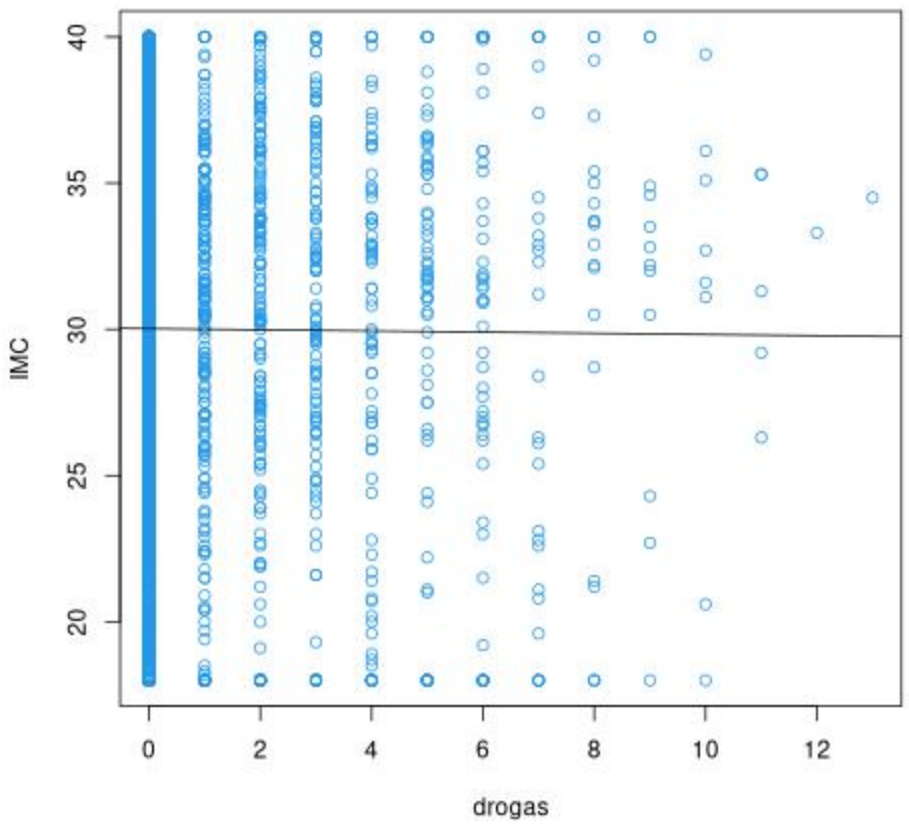

Variables cualitativas

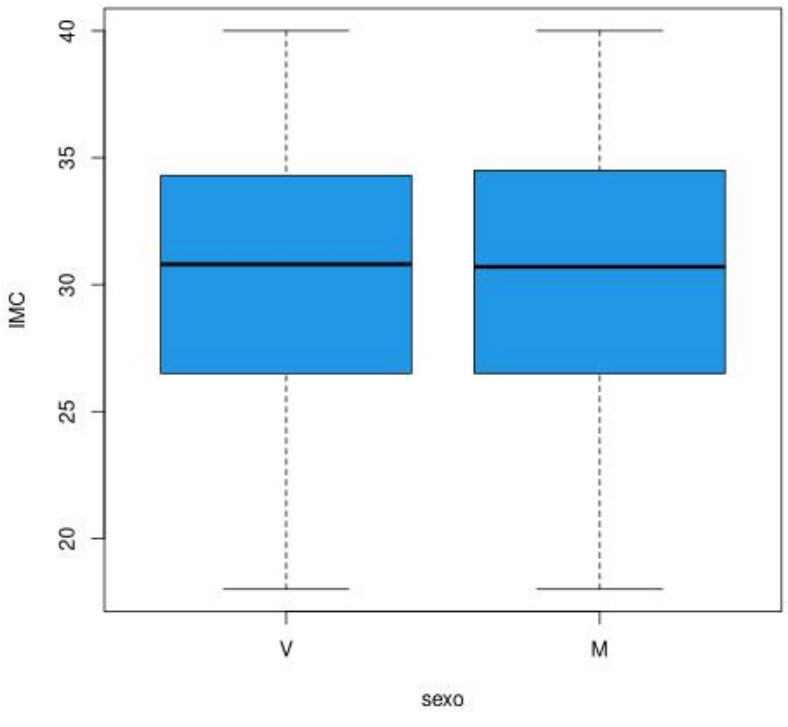
IMC
40
35
30
25
20
V
M
sexo

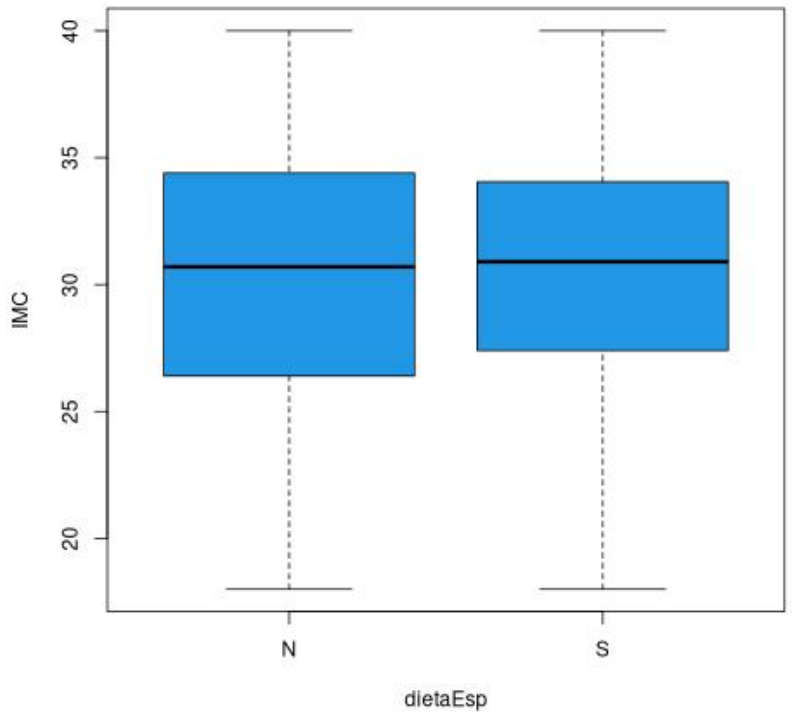
IMC
40
35
30
25
20
N
S
dietaEsp

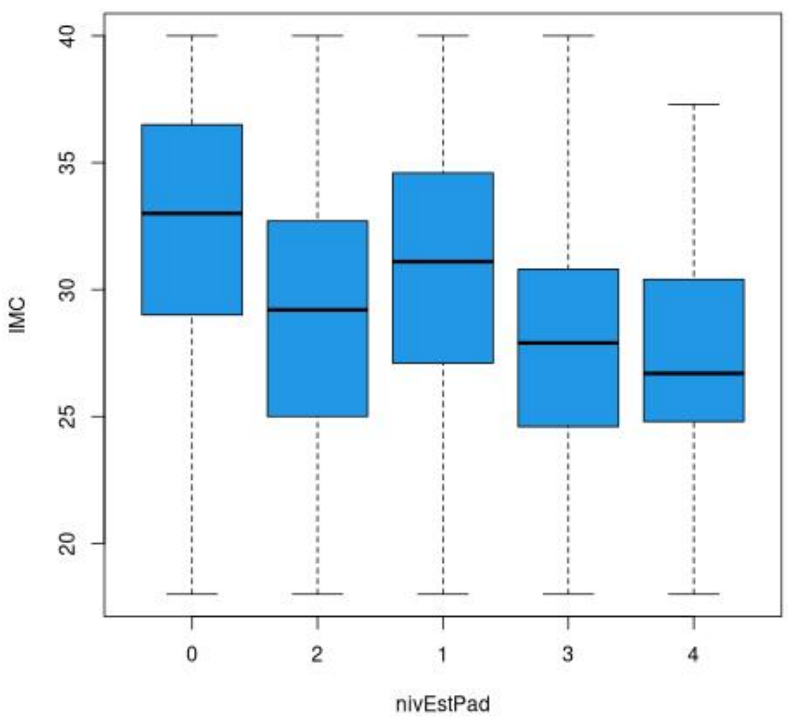
IMC
40
35
30
25
20
0
2
1
3
4
nivEstPad

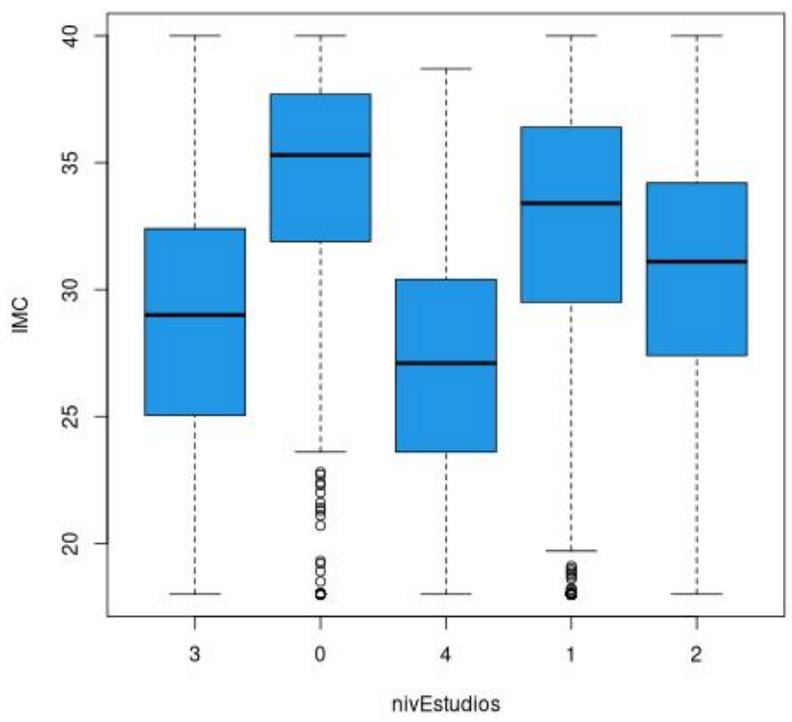
IMC
40
35
30
25
20
3
0
4
1
2
nivEstudios

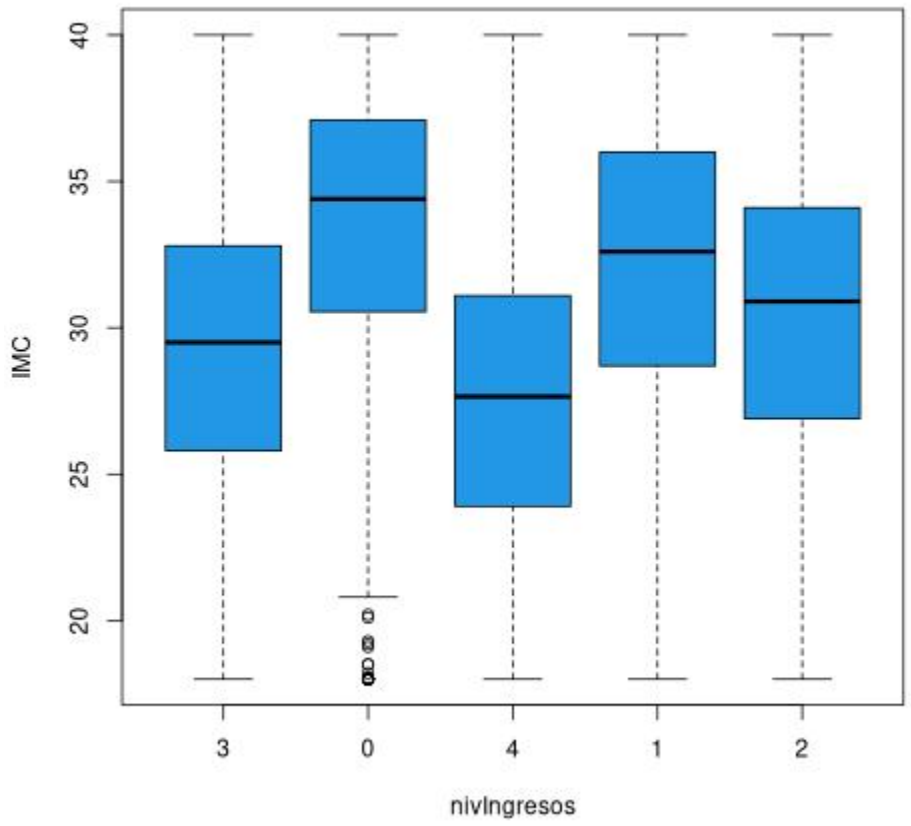
IMC
40
35
30
25
20
3
0
4
1
2
nivIngresos

Explicación

A la hora de graficar los datos y su regresión lineal, hay que tener en cuenta si son variables cuantitativas o cualitativas.

Para el primer caso, basta con usar una función `plot(x, y)`, siendo x cada una de las variables explicatorias y siendo y la variable explicada (*IMC*); tras graficar la dispersión de los datos, con `abline(modelo)` se superpone la recta de regresión del modelo generado.

Para el segundo caso, se usa `boxplot(x, y)` y no se superpone la recta de regresión.

Todo el proceso anterior se ha compactado en la función `dibujarModelos()`, que además genera las imágenes como ficheros y tiene encuenta el tipo de variable, por lo que genera cada gráfico correspondiente atendiendo a la variable x que recibe.

Apartado 07

Código de R

```
# Separa un conjunto de datos en 3 subconjuntos disjuntos: Entrenamiento,
# Test y Validacion; que se dividiran segun las proporciones indicadas.
# * datos:  conjunto de datos del que obtener los subconjuntos
# * p1:     porcentaje del subconjunto de Entrenamiento
# * p2:     porcentaje que divide a '1-p1'
obtenerConjuntos <- function(datos, p1, p2) {
  rdatos  <- 1:nrow(datos)
  rTrain  <- sample(rdatos, p1 * length(rdatos))
  rTemp   <- setdiff(rdatos, rTrain)
  rTest   <- sample(rTemp, p2 * length(rTemp))
  rValid  <- setdiff(rTemp, rTest)

  list(entrenamiento=datos[rTrain,], test=datos[rTest,], validacion=datos[rValid,])
}


# Conjuntos obtenidos
conjuntos <- obtenerConjuntos(datos, .6, .5)
```

Resultado

```
> conjuntos
$entrenamiento
# A tibble: 2,970 x 15
    peso altura sexo   edad tabaco  ubes carneRoja verduras deporte drogas dietaEsp
   <dbl>  <dbl> <fct> <dbl>  <dbl> <dbl>     <dbl>    <dbl>   <dbl>  <dbl> <fct>
 1  98.0   1.81 V        44     30     0         8        6       4      0 N
 2  92.8   1.64 M        55      0     0         0        1       1      0 N
 3  74.6   1.58 M        51     40     0         5        0       0      0 N
 4  76.5   1.68 V        21      0     0         5        0       3      0 N
 5 120.    1.78 M        52      0     0         0        0       0      0 N
 6  94.1   1.58 M        58      0     0         1        5       0      2 N
 7 100     1.71 M        24      0     0         0        0       7      0 N
 8  48.4   1.64 M        59    140     5         0       12       1      0 S
 9  78.8   1.79 V        35     10     0         3        0       0      0 N
10  82.4   1.78 V        22      0    17         1        6       0      0 N
# … with 2,960 more rows, and 4 more variables: nivEstPad <fct>, nivEstudios <fct>,
#   nivIngresos <fct>, IMC <dbl>

$test
# A tibble: 990 x 15
    peso altura sexo   edad tabaco  ubes carneRoja verduras deporte drogas dietaEsp
   <dbl>  <dbl> <fct> <dbl>  <dbl> <dbl>     <dbl>    <dbl>   <dbl>  <dbl> <fct>
 1  52.6   1.71 M        63    180     1         7        0       2      0 N
 2  48.4   1.64 M        58    220    13         0        0       0      1 N
 3  55.1   1.75 V        18    110     3         0        9       8      6 N
 4 114.    1.69 V        63      0     0         2       19       7      0 N
 5  97.2   1.74 V        41      0     5         1        9      10      0 N
 6  76.3   1.69 V        18      0     0         1        0       0      0 N
 7  94.2   1.57 M        47      0     0         2        1       7      0 N
 8  87.3   1.57 M        47      0     0         0       10       2      0 N
 9  99.7   1.73 V        33      0     0         3       12      16      2 N
10 103.    1.63 M        66      0    11         0        8       6      2 N
# … with 980 more rows, and 4 more variables: nivEstPad <fct>, nivEstudios <fct>,
#   nivIngresos <fct>, IMC <dbl>

$validacion
# A tibble: 990 x 15
    peso altura sexo   edad tabaco  ubes carneRoja verduras deporte drogas dietaEsp
   <dbl>  <dbl> <fct> <dbl>  <dbl> <dbl>     <dbl>    <dbl>   <dbl>  <dbl> <fct>
```

```
 1  68.0   1.67 M        21      0    11         0       13       0      1 N
 2  75.3   1.62 M        30      0    10         2        0       0      0 N
 3  81.2   1.7  V        44     30     0         3        0       0      5 N
 4  90.7   1.8  V        28      0    13         0        0       0      0 N
 5  86.0   1.74 V        33      0     8        11        4       0      2 N
 6  54.8   1.6  M        34     80     3         2        2       5      8 N
 7  92.0   1.72 M        27     10    11         1        8       0      0 N
 8 104.    1.76 M        54      0     3         4       12      13      0 N
 9 107.    1.71 V        56      0     4         0       13       4      0 N
10  80.4   1.68 V        38      0    23         0        1       0      0 N
# … with 980 more rows, and 4 more variables: nivEstPad <fct>, nivEstudios <fct>,
#   nivIngresos <fct>, IMC <dbl>
```

Funciones:

- `obtenerConjuntos()` que divide un conjunto de datos en 3 subconjuntos.

Variables:

- `conjuntos` que contiene 3 subconjuntos disjuntos:
  - `entrenamiento`, correspondiente al 60 % de los datos.
  - `test`, correspondiente al 20 % de los datos.
  - `validacion`, correspondiente al 20 % de los datos.

Explicación

Para poder evaluar correctamente la predicción de un modelo, primero es necesario eliminar fluctuaciones estadísticas que existen entre las variables; para ello, se usa la técnica de separar el conjunto de datos en 2 subconjuntos disjuntos: uno para entrenar el modelo, y otro más pequeño para probarlo. Esto además, elimina el problema de que se produzca sobreajuste.

En este caso sin embargo, se usará un tercer conjunto del mismo tamaño que el conjunto de test, que permitirá medir la calidad del modelo de una forma más objetiva.

Para ello, se almacenan los subconjuntos en `conjuntos`, obtenidos a través de `obtenerConjuntos(datos, 0.6, 0.5)`.

Se obtiene un conjunto de entrenamiento con un tamaño del 60 % del original, y los datos restantes (40 %) se dividen en 2 subconjuntos de un 50 % cada uno ($0.4 \cdot 0.5 = 0.2$), resultando en los otros 2 subconjuntos: test con un 20 %, y validación con otro 20 %.

Apartado 08

Código de R

```
# Funciones ---------------------------------------------------------------
# Calcula los valores: MSE, varY, R2 y RÂ² a partir de un modelo.
# * datos:  conjunto de datos del modelo
# * modelo: modelo
# * y:      variable a explicar
calcularR2 <- function(df, mod, y) {
  MSE  <- mean((df[[y]] - predict.lm(mod, df)) ^ 2)
  varY <- mean(df[[y]] ^ 2) - mean(df[[y]]) ^ 2

  R2   <- 1 - MSE / varY
  R2a  <- 1 - (1- R2) * (nrow(df) - 1) / (nrow(df) - mod$rank)


  tibble(MSE=MSE, varY=varY, R2=R2, R2a=R2a)
}


# Calcula el coeficiente de determinaciÃ³n (RÂ²) ajustado a partir
# de un conjunto de entrenamiento y un conjunto de test.
# * dfTrain:  conjunto de entrenamiento
# * dfTest:   conjunto de test
# * y:        variable explicada
# * x:        variable explicatoria
calcularR2ajustado  <- function(dfTrain, dfTest, y, x) {
  modelo            <- ajusteLineal(dfTrain, y, x)
  coeficientes      <- calcularR2(dfTest, modelo, y)


  coeficientes$R2a
```

```
  }


# Calculos ------------------------------------------------------------------

  # Variables predictoras
  predictoras <- names(datos[-length(datos)])   # Todas menos 'IMC' (la ultima)


  # Calcular los 14 RÂ² de los 14 modelos lineales unidimensionales
  r2a <- predictoras %>% map_dbl(calcularR2ajustado, dfTrain=conjuntos$entrenamiento, dfTest=conjuntos$test, y="IMC")


  # Obtener la mejor variable para una prediccion unidimensional
  mejorVariable <- predictoras[which.max(r2a)]


  # Obtener el mejor modelo usando el conjunto de entrenamiento
  mejorModelo <- ajusteLineal(conjuntos$entrenamiento, "IMC", mejorVariable)

    # Obtener su RÂ² con el conjunto de test
    evaluacionTest <- calcularR2(conjuntos$test, mejorModelo, "IMC")

    # Obtener su RÂ² con el conjunto de validacion
    evaluacionValidacion <- calcularR2(conjuntos$validacion, mejorModelo, "IMC")
```

Resultado

```
> predictoras
 [1] "peso"        "altura"      "sexo"        "edad"        "tabaco"
 [6] "ubes"        "carneRoja"   "verduras"    "deporte"     "drogas"
[11] "dietaEsp"    "nivEstPad"   "nivEstudios" "nivIngresos"

> r2a
 [1]  0.8466999320 -0.0015412904 -0.0009151768  0.3058570048  0.4616058156
 [6]  0.0076416906 -0.0012383140  0.0065498871  0.0121926236 -0.0014304505
[11] -0.0014070115  0.0651550267  0.1592479228  0.1285421465

> mejorVariable
[1] "peso"

> mejorModelo

Call:
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
(Intercept)         peso
     4.6684       0.2915

> evaluacionTest
# A tibble: 1 x 4
    MSE  varY    R2   R2a
  <dbl> <dbl> <dbl> <dbl>
1  5.55  36.3 0.847 0.847

> evaluacionValidacion
# A tibble: 1 x 4
    MSE  varY    R2   R2a
  <dbl> <dbl> <dbl> <dbl>
1  5.55  35.1 0.842 0.842
```

Funciones:

- `calcularR2()` que calcula tanto el R^2, como el MSE, la σ_y^2 y el R^2 ajustado.
- `calcularR2ajustado()` que calcula el R^2 ajustado usando un conjunto de entrenamiento y otro de test de forma directa, usando la función anterior.

Variables:

- `predictoras` con el nombre de todas las variables explicatorias.
- `mejorVariable` con el nombre de la variable que mejor predice *IMC* en un modelo unidimensional.
- `mejorModelo` con el modelo resultante de aplicar la mejor variable.
- `evaluacionTest` con los datos resultantes de evaluar el modelo con el conjunto de test.
- `evaluacionValidacion` con los datos resultantes de evaluar el modelo con el conjunto de validación.

Explicación

Usando los subconjuntos obtenidos en el apartado anterior y aplicando programación funcional, se crean las funciones `calcularR2()` y `calcularR2ajustado()` para realizar una búsqueda de la variable explicatoria más significativa para generar un modelo de regresión lineal unidimensional.

Se calculan los R^2 ajustados de todos los modelos posibles con las 14 variables explicatorias en la variable `predictoras`, porque la variable que genere un modelo con mayor R^2 ajustado será el mejor de todos los generados.

Finalmente, se evalúa el `mejorModelo` con el conjunto de test así como con el conjunto de validación, obteniendo en ambos casos un R^2 bastante cercano a 1*.

** Esto se deba, posiblemente, a la generación aleatoria de los valores de mi dataframe.*

Apartado 09

Código de R

```
# Funciones ------------------------------------------------------------------
# La funcion 'ajusteLineal()' del apartado 05 se ha modificado para
# que pueda reutilizarse en este apartado (ahora es compatible con ambos)


# Encuentra el mejor ajuste lineal usando un conjunto de variables y
# calculando sus R² ajustados con conjuntos de Entrenamiento y de Test.
# * dfTrain:      conjunto de entrenamiento
# * dfTest:       conjunto de test
# * predictoras:  variables explicatorias del modelo
obtenerMejorAjusteLineal <- function(dfTrain, dfTest, predictoras) {

  # Variables iniciales
  mejoresVariables  <- character(0)
  R2a               <- 0

  # Bucle del algoritmo
  repeat {
    # Inicializar
    R2as      <- map_dbl(predictoras, ~calcularR2ajustado(dfTrain, dfTest, "IMC", c(mejoresVariables, .)))
    i         <- which.max(R2as)
    mejorR2a  <- R2as[i]

    if (mejorR2a <= R2a) {
      break
    }

    # Mostrar por la consola los valores calculados durante la ejecucion
    cat(sprintf("%1.8f %s\n", mejorR2a, predictoras[i]))

    # Actualizar los valores para la siguiente iteracion
    R2a               <- mejorR2a
    mejoresVariables  <- c(mejoresVariables, predictoras[i])
    predictoras       <- predictoras[-i]
  }

    modelo <- ajusteLineal(dfTrain, "IMC", mejoresVariables)


    list(variables=mejoresVariables, modelo=modelo)
  }


# Calculos -------------------------------------------------------------------

  predictoras <- names(datos[-length(datos)])   # Todas menos 'IMC' (la ultima)
  mejorModelo <- obtenerMejorAjusteLineal(conjuntos$entrenamiento, conjuntos$test, predictoras)$modelo
```

Resultado

```
> predictoras
 [1] "peso"        "altura"      "sexo"        "edad"        "tabaco"
 [6] "ubes"        "carneRoja"   "verduras"    "deporte"     "drogas"
[11] "dietaEsp"    "nivEstPad"   "nivEstudios" "nivIngresos"

> mejorModelo

Call:
```

```
lm(formula = str_c(y, "~", str_c(x, collapse = "+")), data = datos)

Coefficients:
 (Intercept)          peso        altura        tabaco          edad  nivEstudios0
   58.226733      0.324573    -33.475439     -0.005628      0.012892      0.300055
nivEstudios4  nivEstudios1  nivEstudios2        drogas          ubes      verduras
   -0.153866      0.224767      0.127218      0.034555     -0.010558      0.005403
```

Funciones:

- `obtenerMejorAjusteLineal()` que genera el mejor modelo a partir de un conjunto de entrenamiento, uno de test, y unas variables predictoras.

Variables:

- `predictoras` nombres de las variables para generar el modelo de variables simple.
- `mejorModelo` modelo generado con la mejor de las variables simples.

Por otra parte, `obtenerMejorAjusteLineal()` muestra de forma iterativa la evolución de los valores obtenidos en su cálculo. Esta opción viene habilitada por defecto.

```
> mejorModelo <- obtenerMejorAjusteLineal(conjuntos$entrenamiento, conjuntos$test, predictoras)$modelo
0.84857067 peso
0.99325355 altura
0.99328690 tabaco
0.99336039 edad
0.99349094 nivEstudios
0.99359004 deporte
0.99371819 ubes
0.99381671 drogas
```

He usado 8 decimales porque en mi caso, salen valores muy parecidos.

Explicación

Finalmente, se usarán varias variables para generar un modelo óptimo.

Pese a que podría hacerse de muchas formas (aplicar logaritmos, modelos aditivos...), se estudiará qué modelo con variables simples es mejor.

Igual que en el apartado anterior, primero se obtendrán las variables sobre la que iterar una función que genere el modelo (en este caso, `obtenerMejorAjusteLineal()`) y se obtendrá el modelo con la mejor de esas variables.

En el siguiente apartado, se analizarán los datos obtenidos en este.

Apartado 10

Código de R

```
evaluacion <- calcularR2(validacion, mejorModelo, "IMC")
```

Resultado

```
> evaluacion
# A tibble: 1 x 4
    MSE  varY    R2   R2a
  <dbl> <dbl> <dbl> <dbl>
1 0.207  35.1 0.994 0.994
```

Variables:

- `evaluacion` que ofrece datos sobre la calidad del modelo de variables simples.

Explicación

Los valores del MSE así como del R^2 ajustado indican que hay algún tipo de anomalía en los datos recibidos del dataframe, ya que si fuera un caso real no estarían tan cercanos al valor teórico que representa una «predicción perfecta».

Apartado 11

¿Qué utilidad podría tener el modelo matemático obtenido?

Ya que el modelo se ha construido a partir de un conjunto de datos que giran en torno al cálculo del *IMC*, un posible uso podría ser el de predecir el *IMC* en base a un mayor número de factores o cualquier otra medida parecida.

¿Qué puede deducirse sobre la relación entre las variables a partir del modelo?

Como la variable *IMC* es un cálculo directo de las variables *peso* y *altura*, una de ellas ha estado siempre presente en las variables más influyentes a la hora de calcular los mejores modelos.

¿Qué problemas se han encontrado en el desarrollo?

Quitando mi poca experiencia con R y entender algunos conceptos estadísticos -porque no se me da especialmente bien-, diría que el principal problema que me he encontrado ha sido la complejidad que supone realmente generar un modelo adecuado y qué camino seguir, qué métodos utilizar, qué variables… el proceso de selección.

Por otra parte, el último dato calculado indica una predicción fuera de lo normal, «demasiado buena», lo que podría deberse a una distribución excepcionalmente «anormal» de los datos del dataframe.

¿Qué más me ha llamado la atención en el proceso?

Lo grande que es la estadística y que, para una sola cosa, existen infinitas formas de calcularla.

Y sin embargo, la potencia de R no queda desapercibida, ya que puede dar lugar a algoritmos y cálculos muy cómodos, junto a una presentación intuitiva de los datos en la propia consola.

¿Qué más podría hacerse y cómo plantearlo?

Podrían usarse variables combinadas modificando el apartado 09 y 10, y estudiar qué modelo presenta una mejor predicción: el modelo de variable simples, el modelo con variables combinadas, cómo combinarlas…

También podrían usarse otras técnicas, para generar el modelo, como aplicar logaritmos.